Cats Company

AI-NATIVE 社交基础设施

平台 × 记忆 × 智能体 — 三位一体

Internal Sync · 2025

我们在做三件事

⚙

XiaoBa

Agent Runtime。类似 Claude Code 的智能体框架，28+ 工具，Skill 系统，支持挂载能力模块，部署即上线。

💬

Cats Company

AI-Native 社交平台。Bot 和人用同一套协议，Agent 是一等公民。用户加好友就能用 Agent，方便分发和售卖。

🧠

GauzMem

记忆引擎。知识图谱 + 向量检索 + 记忆代谢。给 Agent 提供跨会话、无限长的连续记忆。

怎么走到**这一步的**

起点 我们做了 XiaoBa，挂在飞书上跑，体验不错。但飞书限制太多 —— 消息格式受限、API 能力有限、没法自由分发和售卖。我们需要一个**自己控制的平台**。

平台 所以我们做了 Cats Company —— 一个 AI 友好的社交平台。Agent 以聊天窗口的形态存在，用户加好友就能用。不是 API marketplace 的一次性调用，而是**持续的对话关系**。

记忆 对话窗口下的 Agent 要能无限聊下去。服务重启 session 丢了，上一条消息都不知道；聊几天后远超 context window，更不可能回忆。要像人一样聊天，**就必须有记忆**。

闭环 我们恰好有 GauzMem。记忆赛道看似鸡肋 —— mem0 这类服务实际上没人真正在用，多数只是无代码平台挂个插件。但对话平台上需要无限沟通的 Agent bot，**是记忆最好的 playground**。三件事自然串成了闭环。

三位一体架构

分发层
Cats Company
AI-Native 社交平台 · IM · Bot Store

状态层
GauzMem
记忆引擎 · 知识图谱 · 向量检索 · 记忆代谢

能力层
XiaoBa
Agent Runtime · 28+ Tools · Skill System

> *三层各自独立可用，也可以全栈集成。第三方 Agent 可以只接平台做分发，也可以只用 GauzMem 做记忆，不强绑定。*

Cats Company 社交平台

为什么是社交平台，而不是 API marketplace

统一协议

Bot 和人使用同一套 WebSocket 协议，同一套消息格式。在系统层面，Agent 就是一个用户，不是挂载的插件。

第三方接入

Bot SDK（Go + Python），API Key 认证。第三方开发者接入自己的 Agent，不需要了解平台内部实现。

分发 = 加好友 = 变现

用户浏览 Agent、加好友、在聊天窗口直接使用和付费。Agent 的分发和售卖变成社交行为，不是 API 调用。**这是我们当前最直接的变现路径。**

> *API marketplace 是一次性调用关系。社交平台提供的是持续对话关系 —— 这才是 Agent 真正需要的分发形态，也是最自然的付费场景。*

GauzMem 记忆引擎

记忆赛道的真实卡位

现状：Claude Code、Cursor 这类 agent 都摒弃了记忆管理，靠 tool-based search + context window + 模型自身能力来处理文档。mem0 等记忆服务实际上没有真实用户 —— 多数只是无代码平台挂个插件，没有产生实际价值。

但在对话平台上，Agent 需要在一个聊天窗口里无限沟通下去。服务重启 session 就没了，聊几天就超出 context window。这个场景下，记忆不是锦上添花，是**刚需**。Cats Company 是 GauzMem 最好的 playground。

核心设计：写入快，消化慢，回忆自然

Fast Path · 同步秒级

信息进来，同步完成四件事就返回：存原文、LLM 提取原子事实 + 显式关系、生成 embedding、标记待代谢。

MySQL + Neo4j + Qdrant 三层同步写入

Metabolism · 异步消化

ReAct 模式的 LLM Agent 按"不舒适度"游走：消歧（"他"→"John"）、建联想关系、合并重复、标记低质量。

不是无限堆积，是有选择地记住

Retrieval · 按需回忆

被动回忆：语义搜索 → 图扩展 → 连通分量聚类，渲染成树形结构填入 prompt。

主动搜索：作为 tool 给 agent 调用，返回 raw JSON。

XiaoBa Agent Runtime

起点：我们自己需要一个能挂载能力、能部署、能卖的 Agent 框架

工具集

28+ 内置工具：文件读写、Shell 执行、代码搜索、任务规划、子 Agent 调度。覆盖日常开发和办公场景。

Skill 系统

用 Markdown 定义 Skill（系统提示 + 工具权限 + 触发条件）。新增能力不需要改代码，写一个 .md 文件就行。

已验证的集成

已集成 GauzMem 做记忆。已对接飞书 IM 跑通。接入 Cats Company 后，部署一个实例就是一个可售卖的 Agent。

为什么是三位一体

不是设计出来的组合，是需求自然推导出来的闭环

→ **平台带来真实场景**：用户在聊天窗口和 Agent 持续沟通，产生了对记忆的刚需。没有平台，记忆服务就是 mem0 —— 没有真实用户。

→ **记忆让 Agent 可用**：有了记忆，Agent 才能在对话窗口里像人一样持续沟通。用户留存和体验直接取决于记忆质量。

→ **Runtime 降低供给门槛**：XiaoBa 让开发者（包括我们自己）快速部署 Agent。更多 Agent 入驻，平台生态更丰富。

→ **对第三方同样成立**：任何第三方 Agent 接入平台后，都可以挂载 GauzMem 获得记忆能力。记忆服务从我们自用变成平台基础设施，可以收费。

商业模式

分发层

平台抽成 / 订阅

Agent 分发收入分成
用户高级功能订阅
Bot Store 上架费

状态层

记忆按量计费

存储费（知识图谱容量）
检索调用费
企业私有化部署

能力层

托管 / 授权

Agent 托管运行费
企业版 Runtime 授权
定制 Skill 开发

当前进度

Cats Company

- WebSocket 实时通信
- 用户系统 & 好友关系
- Bot SDK (Go + Python)
- 群聊功能
- Bot Store 开发中
- 富媒体消息

GauzMem

- Fast Path 同步写入（秒级）
- 三层存储（MySQL + Neo4j + Qdrant）
- Metabolism Agent（异步消化）
- Passive Recall（被动回忆）
- Active Search（主动搜索 tool）
- REST API
- 持续打磨 & 稳定性优化

XiaoBa

- 核心 Agent 框架
- 28+ 工具集
- Skill 系统
- 飞书集成
- GauzMem 深度集成
- Cats Company 接入

* 进度信息待团队确认更新

下一步重点

1. 三端打通

XiaoBa 通过 Bot SDK 接入 Cats Company，GauzMem 作为平台默认记忆后端。跑通一个完整的 Agent 从部署到被用户使用的链路。

2. 第一个可用的 Agent 产品

在 Cats Company 上部署我们自己的 XiaoBa Agent，验证完整体验：加好友、聊天、记忆跨会话、Skill 调用。

3. 各模块持续打磨

GauzMem 性能优化和稳定性、Cats Company 富媒体消息和 Bot Store、XiaoBa Skill 生态扩展。各自推进，定期集成验证。

平台 × 记忆 × 智能体

我们已经把大部分做出来了。下一步是把它们串起来，跑通闭环，然后开放给外部。

CATS COMPANY